Lokal AI med Ollama och Llama

Kom igång

1. Installera Ollama från ollama.com och starta tjänsten.
2. Öppna en terminal och hämta en lokal modell, till exempel `ollama pull llama3.1:8b`. Detta hämtar modellfiler och kan ta tid. Välj en modell som ryms i datorns minne.
3. Starta skraparens gränssnitt och välj **Verklig sökning**.
4. Välj **Lokal AI via Ollama** under **AI för klassificering**.
5. Ange modellens fullständiga namn inklusive tagg, till exempel `llama3.1:8b`. `ollama list` visar de modeller du har installerat.
6. Behåll normalt adressen `http://localhost:11434`. Ange inte `/api` eller `/v1`.
7. Tryck på **Testa anslutning till Ollama**. Kontrollen hämtar bara modellistan.
8. Välj kommuner/regioner och ange utredningsfråga och sökord. Starta sökningen.

Sökmetoden ändras automatiskt till **Genomsök webbplatser** när du väljer Ollama. Denna kombination behöver ingen OpenAI-nyckel. Skraparen hämtar fortfarande källor från de publika webbplatser du har valt.

Om du aktivt väljer **Webbsökning och genomsökning** eller **Webbsökning med OpenAI** skickas sökfrågorna till OpenAI och en API-nyckel behövs för sökningen. Själva textklassificeringen, verifieringen och konfliktbedömningen körs ändå med Ollama. Det finns ingen automatisk växling till OpenAI om ett lokalt modellanrop misslyckas.

Modell och prestanda

`llama3.1:8b` är ett exempel, inte ett krav eller en kvalitetsgaranti. Du kan ange en annan nedladdad modell som fungerar med Ollamas strukturerade JSON-svar. Appen hämtar, startar eller installerar inte modeller åt dig. Välj inte en Ollama-molnmodell. Modellnamn som slutar med `:cloud` eller `-cloud` avvisas.

Under **Inställningar för lokal modell** kan du ändra kontextfönster och väntetid. Standardvärdena i gränssnittet är 32 768 token och 600 sekunder per anrop. Kontexten måste rymma instruktioner, källtext, JSON-schema och modellens svar; ett för litet fönster kan göra att Ollama tappar delar av texten. Större kontext kräver mer minne. Anpassa vid behov dokumentens textfönster i YAML-kodboken och granska ett litet prov innan du skalar upp. Appen kan inte mäta modellens träffsäkerhet automatiskt.

Kontroll och spårbarhet

Varje klassificering använder samma JSON-schema och citatkontroller som OpenAI-läget. Ofullständiga svar, ogiltig JSON, okända kategorier och felaktiga citat godtas inte som forskningsfynd. Råa modellsvar sparas, och verifiering/konfliktbedömning finns kvar.

Cacheidentiteten skiljer på leverantör, serveradress, modellnamn, kontext och anropsinställningar. Om du byter modellvikter men behåller samma tagg: använd en ny cache

eller kommandoradens `--refresh`. Uppspelning med `--offline` använder enbart sparade svar och behöver varken Ollama eller OpenAI. Det är skilt från en ny lokal AI-körning, som behöver en igångsatt Ollama-tjänst.

Endast `localhost`, `127.0.0.1` och `::1` accepteras som serveradress. Anrop till den lokala tjänsten går inte via datorns HTTP-proxy och skickar ingen OpenAI-nyckel.

Kör från kommandoraden

```
municipal-research run --config examples/local_llama.yaml --locations examples/municipalities.
csv --run-dir runs/local-llama --limit 1
```

YAML-exemplet anger lokal leverantör och samma modell för samtliga bedömningsroller. `llm.max_calls` räknar även lokala modellanrop. Inga nya Python-bibliotek behövs för Ollama-anslutningen; skraparens befintliga HTTP-klient används.

Om Ollama inte svarar

Starta Ollama, kontrollera att modellen finns med i `ollama list`, och kontrollera modelltagg och serveradress. Vid långsamma anrop kan du öka väntetiden eller välja en mindre modell. Den tekniska loggen visar om ett modellanrop misslyckades.

Demonstrationsläget använder alltid fasta påhittade svar och kontaktar inte Ollama. Anslutningskoden är testad med simulerade HTTP-svar och källor. Ingen verklig Llama-körning eller kvalitetsbedömning av en lokal modell har utförts i utvecklingsmiljön.

Tekniska referenser: Ollamas strukturerade svar och API för chatt.